




#21 20231020072 Samuel Alberto Leal Sáenz

# Análisis del Dataset Iris

Entrenamiento, comparación y evaluación de algoritmos de Aprendizaje Automático aplicados al conjunto de datos clásico de Fisher – KNN, Bayes, Árbol de Decisión y más.

# El Dataset Iris



## Breve recuento del dataset

El dataset Iris es un **benchmark clásico** en ML: 150 muestras, 3 clases y 4 atributos numéricos que lo hacen ideal para comparar clasificadores.

Setosa · Versicolor · Virginica — medidas de sépalos y pétalos.

150

muestras totales


3

especies de lirios

4

características (cm)

Iris Dataset



# Flujo de Trabajo en Python

## Dividir datos

`train_test_split 70/30 con  
random_state=42.`

## Entrenar modelo

`fit()` sobre el conjunto de  
entrenamiento.

## Cargar datos

`load_iris()` para obtener el  
dataset.

## Evaluar resultados


`accuracy_score` y  
`classification_report`.

El código base usa `scikit-learn` con `test_size=0.3` y `random_state=42` para reproducibilidad. La separación 70/30 garantiza suficientes datos para entrenamiento sin comprometer la validación.

# FLUJO DE ÁRBOLES DE DECISIÓN

ESTE MODELO DEMUESTRA LAS DISTINTAS CARACTERÍSTICAS DE LAS PLANTAS DEL DATASET POR MEDIO DE CONSULTAS Y COMPROBACIONES, FILTRANDO LA INFORMACIÓN CON LOS VALORES DESPLEGADOS.

LOS MÉTODOS DE ENTRENO Y PREDICCIÓN DEL MODELO SON MUY PARECIDAS AL UTILIZADO EN EL MODELO KNN.



# Algoritmos Comparados

No basta con medir precisión – cada algoritmo tiene supuestos sobre los datos que determinan **cuándo y por qué funciona mejor**.



## KNN (k=3)

Clasifica por proximidad. Robusto con fronteras no lineales.  
Sensible a escala y dimensionalidad.

Las plantas al tener diversas características que a su vez son muy cercanas entre sí permiten que este modelo funcione con eficacia ya que son diferenciables mediante las distancias.




## Árbol de Decisión

Genera reglas interpretables. Propenso a sobreajuste pero excelente para entender las separaciones entre clases.

Al ser capaz de generar reglas y condiciones separa las características del Dataset mediante su rápida predicción y da un conjunto de propiedades exactas.

# Resultados y Comparación



## ¿Qué nos dicen los números?

KNN con  $k=3$  alcanza ~97,8% de precisión en el conjunto de prueba — resultado consistente con los valores presentados en los datasets.

- Setosa es **perfectamente separable** por todos los modelos
- Versicolor y Virginica generan los únicos errores de clasificación
- La matriz de confusión confirma 0 errores en Setosa

Al tener una mayor tasa de precisión permite generar una mayor seguridad al aplicar dicho modelo.

# Conclusiones

- **Justifica tu algoritmo según los datos**  
KNN funciona bien en Iris porque el espacio es de baja dimensión y las clases son localmente compactas. En datasets de alta dimensión, su rendimiento cae por la "maldición de la dimensionalidad".
- **La precisión no lo es todo**  
Un Árbol de Decisión con igual precisión que KNN ofrece **reglas interpretables**, lo que es una ventaja crucial en contextos donde importa explicar la decisión.
- **Visualiza para comprender y comunicar**  
Usar distintos modelos ayuda a detectar solapamiento entre clases, outliers y a validar intuiciones a la hora de entrenarlos.

✓ Los resultados obtenidos con scikit-learn son consistentes con las clasificaciones presentadas en el dataset, validando a su vez tanto el código como la teoría.